

Comprensión de los Datos

```
In [1]: #importa librerías
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Descripción de Variables

Pclass Passenger Class (1 = 1st; 2 = 2nd; 3 = 3rd): Categórica Nominal survival

Survival (0 = No; 1 = Yes)

name Name

sex Sex

age Age

sibsp Number of Siblings/Spouses Aboard

parch Number of Parents/Children Aboard

ticket Ticket Number

fare Passenger Fare (British pound)

cabin Cabin

embarked Port of Embarkation (C = Cherbourg; Q = Queenstown; S = Southampton)

boat Lifeboat

body Body Identification Number

home.dest Home/Destination

Ejemplo: Crear un objeto DataFrame con base en un archivo .csv

```
In [5]: #lee archivo csv
df = sns.load_dataset('titanic')
```

```
In [6]: #Usa función shape para revisar el total de renglones y columnas
df.shape
```

```
Out[6]: (891, 15)
```

```
In [ ]: #Revisa los primeros 5 renglones del dataset usando la función head
df.head()
```

```
In [ ]: #Revisa los últimos 5 renglones del dataset usando la función tail
df.tail()
```

```
In [ ]: #Revisa la información mas completa del conjunto de datos usando la
#Muestra el total de datos, las columnas y su tipo correspondiente,
```

```
df.info()
```

```
In [ ]: #revisa cuántos valores únicos tiene cada atributo del archivo usando
df.nunique()
```

Exploración de Datos

```
In [ ]: #utiliza la función describe() para obtener estadística básica. se
df.describe(include='all', datetime_is_numeric=True)
```

```
In [ ]: #Revisa Valores nulos con función isnull().sum()
df.isnull().sum()
```

```
In [16]: #Revisar valores únicos por columna usando función unique(): nombre
df['sex'].unique()
```

```
Out[16]: array(['male', 'female'], dtype=object)
```

Variables Cuantitativas

Medidas de tendencia central

```
In [ ]: #Edad
#Se puede obtener la media, mediana y moda para
mean_age = titanic['Age'].mean()
median_age = titanic['Age'].median()
mode_age = titanic['Age'].mode()
print("Mean_age:", mean_age)
print("Median_age:", median_age)
print("Mode_age:", mode_age)
```

```
Mean_age: 29.69911764705882
```

```
Median_age: 28.0
```

```
Mode_age: 0 24.0
```

```
dtype: float64
```

Conclusiones: La edad promedio fue 29 La edad al centro es 28 La edad más repetida fue de 24

Variables Categóricas

```
In [ ]: #Para conteo de cada valor en una columna, en orden descendente us
# nombreDataframe.columna.value_counts()
# nombreDataframe['columna'].value_counts()
df['sex'].value_counts()
```

```
In [10]: #Revisa conteo de varias columnas
df['class'].value_counts()
```

Out[10]:

count	
class	
Third	491
First	216
Second	184

dtype: int64

```
In [ ]: # Crear variable familySize que incluya la suma de las columnas Sib
# Mostrar el total por cada tamaño de familia
df['familySize'] = df['sibsp'] + df['parch']
df['familySize'].value_counts()
```

Consulta

```
In [11]: # df.iloc[i]: Accede a la fila en la posición i.
# Acceder a la primera fila
df.iloc[0]
```

Out[11]:

	0
survived	0
pclass	3
sex	male
age	22.0
sibsp	1
parch	0
fare	7.25
embarked	S
class	Third
who	man
adult_male	True
deck	NaN
embark_town	Southampton
alive	no
alone	False

dtype: object

```
In [ ]: # Acceder a las dos primeras filas
df.iloc[:2]
```

```
In [ ]: #Seleccionar columnas, indicando entre corchetes [nombreColumna, no
df[['sex', 'age', 'fare']].head()
```

```
In [ ]: #Selección de filas [indicar dataframe[columna] operador valor]
df[df['fare'] > 50]
```

```
In [ ]: #ordenar usando funcion sort_values(by=atributo, ascending=True/fal.
df.sort_values(by='fare', ascending=False).head()
```

```
In [ ]: #Agrupar por un atributo y calcular función de agregación utilizand
df.groupby('class')['fare'].mean()
```

Crea un subconjunto de **titanic** para el costo mayor a 500

```
In [ ]: # usa el criterio para extraer solo los boletos caros con fare > 50
df[df['fare'] > 500]
```